

Arquiteturas Avançadas de Redes Neurais: Foco em CNNs Baseadas em Memristores

Lucas Kledeglau Jahchan Alves
Vinicius Kazuo Inagaki

USP

2025

- Compreender o funcionamento teórico e físico dos memristores;
- Explorar como CNNs podem ser implementadas com memristores;
- **Analisar vantagens de desempenho e eficiência.**

Conjunto de Dados

Rice Leaf Disease (RLD):

- 5932 imagens;
- 3 classes de doenças e 1 de folhas saudáveis.

Plant Village (PV):

- 61486 imagens;
- 39 classes de doenças de folhas e de espécies saudáveis.




Figure: Mancha marrom em uma folha de arroz (RLD)



Figure: Mancha bacteriana em uma folha de Pessegueiro (PV)

Método de Seleção de Hiperparâmetros

Separação de ambos os conjuntos de dados no artigo: Hold-out:

- 10% Teste;
- Restante:
 - 80% Treino;
 - 20% Validação.

Hiperparâmetros utilizados no artigo:

- Épocas: 60;
- Taxa de Aprendizado: 0.001;
- Cada 20 épocas, Taxa de aprendizado é dividida por 10.

Inicialização dos pesos aleatória (Não presente no artigo).

Hiperparâmetros do Memristor

Hiperparâmetros específicos do Memristor:


- Épocas ex-situ: 50;
- Épocas in-situ: 10;
- Tamanho crossbar array: 128x128;
- Entrada Máxima: 3V;
- Taxa de Aprendizado in-situ: 0.0001;
- Não-Idealidade: True;
- Resistências On: 100 Ohms;
- Resistência Off: 16000 Ohms;

- 1 Resultados - Plant Village
- 2 Resultados - Rice Leaf Diseases
- 3 Discussão dos Resultados

- 1 Resultados - Plant Village
- 2 Resultados - Rice Leaf Diseases
- 3 Discussão dos Resultados

- Acurácia: 97.39%;
- Perda (*loss*) de teste: 0.085;

Matriz de Confusão



Classe (Espécie/Doença)	Precisão	Revocação	F1
Corn – Northern Leaf Blight	91.5%	86.0%	88.7%
Corn – Cercospora/Gray Leaf Spot	88.3%	91.0%	89.7%
Tomato – Early Blight	95.5%	85.0%	89.9%
Tomato – Target Spot	90.4%	93.6%	91.9%
Tomato – Spider Mites	92.0%	95.8%	93.9%

Eficiência Energética




Figure: Consumo de energia por inferência: memristor vs GPU ($50 \times$ mais eficiente).

- 1 Resultados - Plant Village
- 2 Resultados - Rice Leaf Diseases
- 3 Discussão dos Resultados

Matriz de Confusão




Figure: Matriz de confusão normalizada para as 4 classes.

- Acurácia: 99.16%;
- Perda (*loss*) de teste: 0.034;

Classe (Doença)	Precisão	Revocação	F1
Bacterial blight	99.4%	99.4%	99.4%
Blast	98.6%	99.3%	98.9%
Brown spot	99.4%	99.4%	99.4%
Tungro	99.2%	98.5%	98.9%

Eficiência Energética




Figure: Consumo por inferência: memristor vs GPU (50 × mais eficiente).

Resultados

- 1 Resultados - Plant Village
- 2 Resultados - Rice Leaf Diseases
- 3 Discussão dos Resultados**

Discussão dos Resultados

Net	Params Size/ MB	Accuracy Rate /%	
		PV	RLD
MobileNetV2	8.74	97.33	97.81
MobileNetV2(modified)	5.73	97.02	96.88
MobileNetV2(modified)+TA	5.74	98.86	98.82
MobileNetV2(modified)+CNSN	5.78	97.65	97.57
TTN-MobileNetV2(ours)	5.79	99.03	99.16

Figure: Teste de ablação

Discussão dos Resultados

Table: Comparação de desempenho entre variações do MobileNetV2

Net	Params Size / MB	Accuracy Rate / % PV	Accuracy Rate / % RLD
MobileNetV2 (1.0)	8.80	98.46	99.53
MobileNetV2 (0.75) + Mish	5.46	98.55	98.88
MobileNetV2 + TA	5.48	98.56	99.44
MobileNetV2 + CNSN	5.49	97.65	97.57
MobileNetV2 (Memristor)	5.49	97.39	99.16

- Depreciação da Biblioteca principal MemTorch:
 - A Biblioteca não funciona com as últimas versões do Python e CUDA;
 - Reinstalação das versões antigas (e não seguras) do Python e Pip;
- Memtorch não conseguindo usar a GPU tanto para treinamento como inferência:
 - Aumentou o tempo de treinamento;
 - Aumentou o tempo de inferência.
- Medição da eficiência energética:
 - Módulo do Memtorch funcionou mas não temos certeza quanto a veracidade;

-  A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, et al., *Attention is all you need*, Proceedings of the 30th Conference on Neural Information Processing Systems (NeurIPS), pp. 6000–6010, 2017.
-  D. Misra, T. Nalamada, A. U. Arasanipalai, and Q. Hou, *Rotate to attend: Convolutional triplet attention module*, Proceedings of the IEEE Winter Conference on Applications of Computer Vision (WACV), pp. 3138–3147, Jan. 2021.
-  Z. Tang, Y. Gao, Y. Zhu, Z. Zhang, M. Li, and D. Metaxas, *CrossNorm and SelfNorm for generalization under distribution shifts*, Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV), pp. 52–61, Oct. 2021.

Referências II



Encyclopaedia Britannica, *Memristor*, Available at: <https://www.britannica.com/technology/memristor>, Accessed: Jun. 9, 2025.



W. Hu, Y. Du, H. Luo, C. Chen, and R. Wei, *An HAM-Based Analytic Modeling Methodology for Memristor Enabling Fast Convergence*, arXiv: Applied Physics, 2018. Available at: <https://api.semanticscholar.org/CorpusID:204904067>



Peng Yao, Huaqiang Wu, Bin Gao, Jianshi Tang, Qingtian Zhang, Wenqiang Zhang, J. Joshua Yang and He Qian, *Fully hardware-implemented memristor convolutional neural network*, arXiv: Nature, 2020. Available at: <https://www.nature.com/articles/s41586-020-1942-4>



GitHub Mementor, *MemmmTorch Package*, Available at:
<https://github.com/coreylammie/MemTorch>, Accessed: Jun. 1,
2025.