

Arquiteturas Avançadas de Redes Neurais: Foco em CNNs Baseadas em Memristores

Lucas Kledeglau Jahchan Alves
Vinicius Kazuo Inagaki

USP

2025

Visão Geral da Apresentação

- 1 Memristors e suas propriedades
- 2 Integração de memristores em arquiteturas de CNNs
- 3 Tecnologias Relacionadas

- Compreender o funcionamento teórico e físico dos memristores
- Explorar como CNNs podem ser implementadas com memristores
- Analisar vantagens de desempenho e eficiência

Visão Geral da Apresentação

- 1 Memristors e suas propriedades
- 2 Integração de memristores em arquiteturas de CNNs
- 3 Tecnologias Relacionadas

Princípio de Funcionamento do Memristor

- O valor da resistência varia:
 - Corrente elétrica;
 - Voltagem;
- Memória intrínseca no próprio material;

- Realização física pelos HP Labs em 2008;
- Dois eletrodos de platina;
- Filme fino de dióxido de titânio;
- Movimento de vacâncias de oxigênio.




Figura: Esquema da implementação física do Memristor

- Memória não volátil;
- Alta densidade em nanoescala;
 - Arquiteturas 3D;
- Eficiência energética superior.
 - baixa potência para manter estados lógicos;

Visão Geral da Apresentação

- 1 Memristors e suas propriedades
- 2 Integração de memristores em arquiteturas de CNNs
- 3 Tecnologias Relacionadas

- Estrutura da CNN implementada:
 - 5 camadas (2 convolucionais, 2 pooling, 1 fully-connected)
 - 8 PEs (Processing Elements) integrados
 - Cada PE com matriz de 2.048 memristores (128×16)
- Estrutura dos memristores:
 - Stack TiN/TaO_x/HfO_x/TiN
 - 32 estados de condutância distintos
 - Integração com tecnologia CMOS 130nm

Visão Geral da Arquitetura




Figura: Arquitetura de 5 camadas para uma CNN

Visão Geral da Arquitetura




Figura: Esquema sobre os sobre a funcionalidade básica de uma mCNN

Método de Treinamento Híbrido

- Duas etapas principais:
 - Treinamento ex situ inicial da CNN
 - Transferência de pesos para memristores
- Otimizações:
 - Ajuste in situ apenas da camada fully-connected
 - Compensação de variações entre dispositivos
 - Redução do overhead de treinamento
- Resultado: recuperação da acurácia após transferência

- Mapeamento de pesos:
 - Quantização em 15 níveis
 - Técnica diferencial com pares de memristores
- Computação paralela:
 - Replicação de kernels convolucionais
 - Processamento simultâneo de diferentes entradas
- Controle de estados:
 - Programação closed-loop
 - Monitoramento de drift


- Precisão de reconhecimento:
 - 96,19% no dataset MNIST
 - 94,08% em ResNet-56 (CIFAR-10)
- Eficiência:
 - 11.014 GOPs/s/W (110× maior que GPU)
 - Densidade: 1.164 GOPs/s/mm² (30× maior)
- Escalabilidade demonstrada em redes maiores

- Confiabilidade:
 - Drift dos estados de condutância
 - Variabilidade entre dispositivos
- Otimizações necessárias:
 - Circuitos periféricos (especialmente ADCs)
 - Interface com sistema
- Escalabilidade:
 - Overhead de programação
 - Consumo energético em arrays maiores

MemTorch

1. Define and train, or import a pretrained torch.nn.Module

2. Convert a DNN to a MDNN



Memristor Model Parameters Crossbar and Peripheral Circuitry Parameters Input Voltage Scaling Parameter Non-Ideal Device Characteristics

Figura: Esquema base do MemTorch

- Aplicações:
 - Processamento de imagens em edge
 - Dispositivos IoT de baixo consumo
 - Sistemas neuromórficos integrados
- Perspectivas futuras:
 - Otimização de materiais e fabricação
 - Escalabilidade para redes maiores
 - Integração com sistemas comerciais

- Primeira demonstração completa de CNN em hardware com memristores
- Método de treinamento híbrido eficiente
- Alta eficiência energética e computacional
- Potencial para sistemas neuromórficos práticos
- Caminho promissor para computação não-von Neumann

Tecnologias Relacionadas

- 1 Memristors e suas propriedades
- 2 Integração de memristores em arquiteturas de CNNs
- 3 Tecnologias Relacionadas

Triplet Attention (TA)

Melhora as representações de características modelando interações cruzadas entre as dimensões espaciais e de canais, em vez de tratá-las de forma independente.

Como funciona:

- Possui 3 ramificações paralelas:
 - Canal–Altura (C–H);
 - Canal–Largura (C–W);
 - Altura–Largura (H–W).
- Cada ramificação:
 - Rotaciona o tensor;
 - Aplica a operação Z-pool (max pooling+average pooling);
 - Aplica um mapa de atenção 2D (conv + sigmoid);
- Os resultados das três ramificações são combinados por médias.

Principais benefícios:

- Leve: baixo overhead comparado a atenção tradicional.
- Melhora generalização e acurácia em CNNs.

Triplet Attention (TA)




Figura: Módulo de Atenção do Triplet Attention

CrossNorm (CN)

CrossNorm melhora a generalização trocando estatísticas de normalização (média e variância) entre amostras de um mesmo mini-batch durante o treinamento.

Como funciona:

- Para cada amostra x , calcule μ, σ .
- Escolha aleatoriamente outra amostra x' do batch e use μ', σ' .
- Normalize:

$$\text{CrossNorm}(x) = \frac{x - \mu'}{\sigma'}.$$

- Em inferência: use μ, σ originais (sem troca).

Principais benefícios:

- Simula *distribution shift* durante o treino.
- Torna o modelo robusto a variações de estatísticas.
- Melhora generalização em condições não vistas.

SelfNorm (SN)

SelfNorm recalibra características usando transformações aprendidas das próprias estatísticas da amostra, preservando sua estrutura intrínseca.

Como funciona:

- Calcule μ, σ de x .
- Aprenda duas funções:

$$f(\mu, \sigma), \quad g(\mu, \sigma).$$

- Reconstrua:

$$y = \left(\frac{x - \mu}{\sigma} \right) (\sigma g(\mu, \sigma)) + \mu f(\mu, \sigma).$$

Principais benefícios:

- Normalização adaptativa por amostra.
- Robustez a mudanças intra e extra-domínio.
- Overhead baixo: pequena rede aprende f e g .

- Revisamos conceitos de memristores físicos;
- Exploramos CNNs baseadas em memristores;
- Entendemos o artigo científico que estudamos e conseguimos implementar e ter resultados equivalentes



D. Misra, T. Nalamada, A. U. Arasanipalai, and Q. Hou, *Rotate to attend: Convolutional triplet attention module*, Proceedings of the IEEE Winter Conference on Applications of Computer Vision (WACV), pp. 3138–3147, Jan. 2021.



Z. Tang, Y. Gao, Y. Zhu, Z. Zhang, M. Li, and D. Metaxas, *CrossNorm and SelfNorm for generalization under distribution shifts*, Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV), pp. 52–61, Oct. 2021.



Encyclopaedia Britannica, *Memristor*, Available at: <https://www.britannica.com/technology/memristor>, Accessed: Jun. 9, 2025.

Referências II



W. Hu, Y. Du, H. Luo, C. Chen, and R. Wei, *An HAM-Based Analytic Modeling Methodology for Memristor Enabling Fast Convergence*, arXiv: Applied Physics, 2018. Available at:
<https://api.semanticscholar.org/CorpusID:204904067>



Peng Yao, Huaqiang Wu, Bin Gao, Jianshi Tang, Qingtian Zhang, Wenqiang Zhang, J. Joshua Yang and He Qian, *Fully hardware-implemented memristor convolutional neural network*, arXiv: Nature, 2020. Available at:
<https://www.nature.com/articles/s41586-020-1942-4>



GitHub Memtorch, *MemmTorch Package*, Available at:
<https://github.com/coreylammie/MemTorch>, Accessed: Jun. 1, 2025.