

Identification of Leaf Disease Based on a Memristor Convolutional Neural Networks

Apresentação Parcial

Lucas Kledeglau Jahchan Alves
Vinicius Kazuo Inagaki

USP

2025

Definição do Problema

Criação do modelo MobileNetV2 capaz de identificar doenças em folhas:

- Maior taxa de acurácia possível;
- Menor tamanho possível dos parâmetros;
- Menor custo computacional.

- Triplet Attention (TA);
- CrossNorm (CN);
- SelfNorm (SN);

Triplet Attention (TA)

Melhora as representações de características modelando interações cruzadas entre as dimensões espaciais e de canais, em vez de tratá-las de forma independente.

Como funciona:

- Possui 3 ramificações paralelas:
 - Canal-Altura (C-H);
 - Canal-Largura (C-W);
 - Altura-Largura (H-W).
- Cada ramificação:
 - Rotaciona o tensor;
 - Aplica a operação Z-pool (max pooling+average pooling);
 - Aplica um mapa de atenção 2D (conv + sigmoid);
- Os resultados das três ramificações são combinados por médias.

Principais benefícios:

- Leve: baixo overhead comparado a atenção tradicional.
- Melhora generalização e acurácia em CNNs.

Triplet Attention (TA)




Figura: Módulo de Atenção do Triplet Attention

CrossNorm (CN)

CrossNorm melhora a generalização trocando estatísticas de normalização (média e variância) entre amostras de um mesmo mini-batch durante o treinamento.

Como funciona:

- Para cada amostra x , calcule μ, σ .
- Escolha aleatoriamente outra amostra x' do batch e use μ', σ' .
- Normalize:

$$\text{CrossNorm}(x) = \frac{x - \mu'}{\sigma'}.$$

- Em inferência: use μ, σ originais (sem troca).

Principais benefícios:

- Simula *distribution shift* durante o treino.
- Torna o modelo robusto a variações de estatísticas.
- Melhora generalização em condições não vistas.

SelfNorm (SN)

SelfNorm recalibra características usando transformações aprendidas das próprias estatísticas da amostra, preservando sua estrutura intrínseca.

Como funciona:

- Calcule μ, σ de x .
- Aprenda duas funções:

$$f(\mu, \sigma), \quad g(\mu, \sigma).$$

- Reconstrua:

$$y = \left(\frac{x - \mu}{\sigma} \right) (\sigma g(\mu, \sigma)) + \mu f(\mu, \sigma).$$

Principais benefícios:

- Normalização adaptativa por amostra.
- Robustez a mudanças intra e extra-domínio.
- Overhead baixo: pequena rede aprende f e g .

Inverted Residual Block




Figura: Bloco Residual Invertido Final do Modelo

O que foi prometido

Net	Params Size/ MB	Accuracy Rate /%	
		PV	RLD
MobileNetV2	8.74	97.33	97.81
MobileNetV2(modified)	5.73	97.02	96.88
MobileNetV2(modified)+TA	5.74	98.86	98.82
MobileNetV2(modified)+CNSN	5.78	97.65	97.57
TTN-MobileNetV2(ours)	5.79	99.03	99.16

Figura: Teste de ablação

O que foi obtido

- Desenvolvimento da redes neurais e treinamento delas:
 - Base MobilenetV2 (1.0);
 - MobileNetV2 (0.75);
 - MobileNetV2 + Mish;
 - MobileNetV2 + Mish + TripletAtt;
 - MobileNetV2 + Mish + TripletAtt + CNSN.
- Criação de gráficos e tabelas para melhor análise dos resultados;
- Resultados promissores em quase todos os modelos.

- Inconsistência de informações do artigo sobre o conjunto de dados:
 - Conjunto RLD mencionado nas referências com 3 classes;
 - Experimento realizado com 4 classes;
 - Omissão de técnicas de Data-Augmentation feitas.
- Tempo para treinamento:
 - Conjunto de dados PV;
 - CrossNorm e SelfNorm.
- Implementação Própria:
 - CrossNorm e SelfNorm com dificuldades na implementação;

Desenhos dos Experimentos

- 1 Conjunto de Dados
- 2 Método de Seleção de Hiperparâmetros
- 3 Medidas de Avaliação

Desenhos dos Experimentos

- 1 Conjunto de Dados
- 2 Método de Seleção de Hiperparâmetros
- 3 Medidas de Avaliação

Conjunto de Dados

Rice Leaf Disease (RLD):

- 5932 imagens;
- 3 classes de doenças e 1 de folhas saudáveis.

Plant Village (PV):

- 61486 imagens;
- 39 classes de doenças de folhas e de espécies saudáveis.




Figura: Mancha marrom em uma folha de arroz (RLD)



Figura: Mancha bacteriana em uma folha de Pessegueiro (PV)

Desenhos dos Experimentos

- 1 Conjunto de Dados
- 2 Método de Seleção de Hiperparâmetros
- 3 Medidas de Avaliação

Método de Seleção de Hiperparâmetros

Separação de ambos os conjuntos de dados no artigo: Hold-out:

- 10% Teste;
- Restante:
 - 80% Treino;
 - 20% Validação.

Hiperparâmetros utilizados no artigo:

- Épocas: 60;
- Taxa de Aprendizado: 0.001;
- Cada 20 épocas, Taxa de aprendizado é dividida por 10.

Inicialização dos pesos aleatória (Não presente no artigo).

Desenhos dos Experimentos

- 1 Conjunto de Dados
- 2 Método de Seleção de Hiperparâmetros
- 3 Medidas de Avaliação

Matriz de Confusão;
Métricas:

- Precisão;
- Sensibilidade (Recall);
- F-score.

Discussão dos Resultados

Modelo básico MobileNetV2(1.0):




Figura: Matriz de confusão para o conjunto RLD

Discussão dos Resultados

Modelo básico MobileNetV2(0.75):




Figura: Matriz de confusão para o conjunto RLD

Discussão dos Resultados

Modelo MobileNetV2(0.75)(Função Mish):




Figura: Matriz de confusão para o conjunto RLD

Discussão dos Resultados

Modelo MobileNetV2(0.75)(Função Mish + Triplet Attention):




Figura: Matriz de confusão para o conjunto RLD

Comparação de Modelos MobileNetV2

Teste de ablação para o conjunto de dados RLD:

Modelo	Tamanho (MB)	Parâmetros	Val Acc (%)
Base MobileNetV2 (1.0)	8.80	2.27M	99.53
Base MobileNetV2 (0.75)	5.46	1.41M	98.88
+ Mish	5.46	1.41M	99.91
+ Mish + TripletAtt	5.48	1.41M	99.44
+ Mish + TripletAtt + CNSN	5.49	1.41M	69.69

Modelo	Precisão (%)	Sensibilidade (%)	F-score (%)
Base MobileNetV2 (1.0)	99.83	99.83	99.83
Base MobileNetV2 (0.75)	98.84	98.82	98.82
+ Mish	99.49	99.49	99.50
+ Mish + TripletAtt	99.50	99.49	99.50
+ Mish + TripletAtt + CNSN	88.35	88.88	88.34

Modelo	Treinamento (s)	Inferência (ms)
Base MobileNetV2 (1.0)	1567.87	28.03
Base MobileNetV2 (0.75)	1662.59	28.92
+ Mish	1360.23	27.66
+ Mish + TripletAtt	1389.30	28.17
+ Mish + TripletAtt + CNSN	6827.80	35.92

Discussão dos Resultados

Teste de ablação para o conjunto de dados PV:

Modelo	Tamanho (MB)	Parâmetros	Val Acc (%)
Base MobileNetV2 (1.0)	8.80	2.27M	98.46
Base MobileNetV2 (0.75)	5.46	1.41M	97.90
+ Mish	5.46	1.41M	98.55
+ Mish + TripletAtt	5.48	1.41M	98.56
+ Mish + TripletAtt + CNSN	5.49	1.41M	87.00

Modelo	Precisão (%)	Sensibilidade (%)	F-score (%)
Base MobileNetV2 (1.0)	98.03	98.02	98.01
Base MobileNetV2 (0.75)	97.67	97.66	97.66
+ Mish	98.42	98.41	98.41
+ Mish + TripletAtt	98.37	98.36	98.35
+ Mish + TripletAtt + CNSN	87.14	86.57	86.20

Modelo	Treinamento (s)	Inferência (ms)
Base MobileNetV2 (1.0)	5043.21	3.17
Base MobileNetV2 (0.75)	3755.25	3.11
+ Mish	6575.56	3.47
+ Mish + TripletAtt	6343.34	3.61
+ Mish + TripletAtt + CNSN	77613.02	12.56

Discussão dos Resultados

Comparação final dos dois testes de ablação:

Net	Params Size/ MB	Accuracy Rate /%	
		PV	RLD
MobileNetV2	8.74	97.33	97.81
MobileNetV2(modified)	5.73	97.02	96.88
MobileNetV2(modified)+TA	5.74	98.86	98.82
MobileNetV2(modified)+CNSN	5.78	97.65	97.57
TTN-MobileNetV2(ours)	5.79	99.03	99.16

Figura: Teste de ablação retirado do artigo

Net	Params Size/MB	Accuracy Rate /%	
		PV	RLD
Base MobileNetV2 (1.0)	8.80	98.46	99.53
Base MobileNetV2 (0.75)	5.46	98.46	98.88
+ Mish	5.46	98.55	99.91
+ Mish + TripletAtt	5.48	98.56	99.44
+ Mish + TripletAtt + CNSN	5.49	87.00	88.69

Tabela: Tabela sobre o teste de ablação feito

O que será feito até a apresentação final

Desenvolvimento do modelo final TTN-MobileNetV2.

Net	Params Size/ MB	Accuracy Rate /%	
		PV	RLD
MobileNetV2	8.74	97.33	97.81
MobileNetV2(modified)	5.73	97.02	96.88
MobileNetV2(modified)+TA	5.74	98.86	98.82
MobileNetV2(modified)+CNSN	5.78	97.65	97.57
TTN-MobileNetV2(ours)	5.79	99.03	99.16

Figura: Teste de ablação

1ª Semana

Ler, estudar e compreender os dois modelos de Memristor:

- Linear Ion Drift Model.
- Data-Driven Verilog-A RRAM.

2ª Semana

Compreender como o artigo aplicou esses conceitos para uma CNN.

3ª Semana

Desenvolvimento do código e aprimoração dos modelos já feitos.

4º Semana

Início dos treinos do modelo e realização de possíveis ajustes.

5º Semana

Continuação dos treinos do modelo e aplicação de medidas de avaliação.

6º Semana

Análise dos resultados e montagem da apresentação final

-  A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, et al., *Attention is all you need*, Proceedings of the 30th Conference on Neural Information Processing Systems (NeurIPS), pp. 6000–6010, 2017.
-  D. Misra, T. Nalamada, A. U. Arasanipalai, and Q. Hou, *Rotate to attend: Convolutional triplet attention module*, Proceedings of the IEEE Winter Conference on Applications of Computer Vision (WACV), pp. 3138–3147, Jan. 2021.
-  Z. Tang, Y. Gao, Y. Zhu, Z. Zhang, M. Li, and D. Metaxas, *CrossNorm and SelfNorm for generalization under distribution shifts*, Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV), pp. 52–61, Oct. 2021.